

Processamento de Linguagem Natural para Sistemas de Decisão Baseados em Dados Não Estruturados

Guilherme Campez Belon¹ and Flavio Almeida de Magalhães Cipparrone²

¹Departamento de Engenharia Mecatrônica e de Sistemas Mecânicos (PMR), Escola Politécnica, Universidade de São Paulo (USP)

²Departamento de Engenharia de Sistemas Eletrônicos (PSI), Escola Politécnica, Universidade de São Paulo (USP)

¹*guilhermecbelon@usp.br*

²*flavio.cipparrone@usp.br*

2 de novembro de 2025

Resumo

Este trabalho desenvolve e valida um sistema de decisão automatizado que integra Processamento de Linguagem Natural (PLN) e Aprendizado por Reforço (RL) para o mercado financeiro. A metodologia proposta transforma dados textuais não estruturados, extraídos de notícias, em um índice de sentimento quantitativo por meio de modelos de linguagem pré-treinados. Este índice é, então, incorporado como variável de estado em um ambiente de negociação simulado, onde um agente de RL é treinado para otimizar estratégias de operação. Para avaliar o impacto da informação textual, foi conduzida uma análise comparativa entre uma estratégia baseada apenas em indicadores técnicos e outra que adiciona o índice de sentimento. Os resultados da simulação histórica, realizada em um portfólio diversificado de ativos, revelam que a inclusão do sentimento, embora não apresente uma melhora estatisticamente significativa de forma agregada, gerou um impacto positivo notável no perfil de risco-retorno de ativos específicos, demonstrando o valor da informação qualitativa em contextos pontuais.

Palavras-chave: Análise de Sentimento Financeiro; Trading Algorítmico; Aprendizado por Reforço Profundo; Sistemas de Decisão Autônomos; Dados Não Estruturados; Engenharia Mecatrônica

1 Introdução

A crescente complexidade dos sistemas de tomada de decisão em engenharia demanda a integração de dados de múltiplas fontes, notadamente informações textuais. Diferentemente dos dados estruturados, que se adequam a formatos padronizados, os textos são classificados como dados não estruturados devido à ausência de uma organização fixa que permita seu processamento direto por algoritmos tradicionais. Embora contenham informações ricas e contextuais, esses dados exigem técnicas específicas para sua interpretação

e aproveitamento.

Nesse cenário, o desenvolvimento de sistemas autônomos capazes de compreender e utilizar dados textuais emerge como um desafio central, impulsionando a adoção de soluções baseadas em Processamento de Linguagem Natural (PLN). O PLN oferece um conjunto de técnicas capazes de transformar dados textuais em sinais quantitativos, que podem ser integrados a sistemas de tomada de decisão automatizados, agregando valor informacional a processos de engenharia.

A integração de técnicas de PLN com sistemas de decisão automatizados, especialmente no domínio financeiro, constitui uma área de pesquisa ativa e promissora. Embora a literatura demonstre o potencial da análise de sentimento, a combinação dessas técnicas com algoritmos de aprendizado por reforço (RL) para a construção de agentes de negociação autônomos representa uma abordagem inovadora, que busca unir a interpretação de dados qualitativos à otimização de políticas de decisão sequenciais.

Este artigo propõe e avalia uma metodologia para integrar um índice de sentimento, derivado de notícias financeiras, a um agente baseado em aprendizado por reforço, a fim de verificar seu impacto no desempenho da estratégia. A aplicação escolhida para validar a estrutura é o *trading* algorítmico no mercado da bolsa norte-americana, contudo, a abordagem foi projetada para ser adaptável a diversos domínios da engenharia. O objetivo não é prever preços, mas construir uma ferramenta que investigue como o sentimento textual influencia o desempenho de estratégias automatizadas.

A análise de sentimento em finanças evoluiu de abordagens baseadas em dicionários, limitadas por sua incapacidade de lidar com nuances contextuais [1], para modelos de aprendizado de máquina supervisionado. Um avanço qualitativo ocorreu com a introdução de arquiteturas *Transformer* [2], como o BERT (*Bidirectional Encoder Representations from Transformers*) [3], que permite uma contextualização bidirecional das palavras. Variantes especializadas, como o *FinBERT* [4], foram pré-treinadas com textos financeiros, aprimo-

rando seu desempenho na classificação de sentimentos nesse setor específico.

Paralelamente, o aprendizado por reforço (RL) tem sido explorado para a automação de sistemas de decisão em ambientes dinâmicos. Algoritmos como o *Proximal Policy Optimization* (PPO) [5] e sua variante recorrente (RPPO) [6] destacam-se pela eficiência e estabilidade, sendo particularmente adequados a ambientes como o mercado financeiro. A estrutura recorrente, em especial, permite ao agente manter uma memória de estados anteriores, o que é essencial para capturar padrões temporais complexos.

Este trabalho se fundamenta na convergência dessas duas áreas, utilizando modelos de linguagem como o *FinBERT* [4] para extrair sinais qualitativos e algoritmos como o RPPO [6] para otimizar uma política de negociação em um ambiente simulado, compatível com a plataforma *Gymnasium* [7].

Dessa forma, as principais contribuições deste artigo são: (i) o desenvolvimento de um pipeline completo e modular para a integração de análise de sentimento em um agente de RL; e (ii) uma análise empírica do impacto heterogêneo da informação de sentimento no desempenho de estratégias de negociação para um portfólio diversificado de ativos. O restante do artigo está estruturado da seguinte forma: a Seção 2 detalha a metodologia de extração de dados, construção do índice de sentimento e o ambiente de RL. A Seção 3 apresenta os resultados quantitativos. Por fim, a Seção 4 apresenta as conclusões finais.

2 Metodologia

A metodologia deste trabalho foi projetada para garantir a reprodutibilidade e a robustez da análise. Ela abrange desde a aquisição de dados brutos até a configuração e o treinamento dos agentes de aprendizado por reforço. As seções a seguir detalham cada etapa do processo.

2.1 Aquisição e Preparação de Dados

O processo inicia-se com a coleta de dados de duas fontes principais, ambas obtidas por meio da API da plataforma Alpha Vantage [8]. A primeira fonte consiste em dados históricos de mercado no formato OHLCV (Open, High, Low, Close, Volume), com granularidade de um minuto, cobrindo o período de 1º de abril a 31 de agosto de 2024.

A coleta foi realizada para um portfólio diversificado de 23 ativos, incluindo empresas como Apple (AAPL), Amazon (AMZN), Google (GOOG), NVIDIA (NVDA) e Tesla (TSLA). No processo, foram coletadas todas as notícias relativas a cada um deles para os dias do intervalo com devido tratamento de remoção de duplicatas.

Como a API de notícias fornece apenas os links para as matérias, foi necessário um passo adicional para extrair o conteúdo textual completo. Para essa tarefa, utilizou-se a biblioteca *BeautifulSoup* [9] para analisar o HTML de cada URL e extrair o texto contido nas

tags de parágrafo (<p>). O resultado é uma base de dados que associa cada notícia ao seu texto bruto e timestamp, pronta para a etapa de processamento de linguagem natural.

2.2 Construção do Índice de Sentimento

A transformação dos dados textuais em um sinal quantitativo é o núcleo desta metodologia. O processo emprega dois modelos de linguagem pré-treinados para extrair o sentimento de cada notícia.

Primeiramente, cada parágrafo do texto de uma notícia é convertido em um vetor numérico (*embedding*) de 1024 dimensões utilizando o modelo *bert-large-uncased* [3]. Esse vetor captura a informação semântica do texto. Em seguida, calcula-se a distância euclidiana entre o *embedding* do parágrafo e vetores de referência previamente definidos para cada ativo. A menor distância indica a proximidade semântica do parágrafo com o ativo em questão e é usada posteriormente como um fator de ponderação.

Paralelamente, o sentimento de cada parágrafo é classificado utilizando o modelo *FinBERT* [4], uma variante do *BERT* [3] especializada no domínio financeiro. Para cada notícia i , o modelo retorna um vetor de probabilidades:

$$\mathbf{f}_i = \begin{bmatrix} f_i^{(\text{neutro})} \\ f_i^{(\text{positivo})} \\ f_i^{(\text{negativo})} \end{bmatrix} \quad (1)$$

Com base nessas probabilidades, calcula-se um score bruto s_i para cada notícia i , conforme a Equação 2.

$$s_i = f_i^{(\text{positivo})} - f_i^{(\text{negativo})} \quad (2)$$

Para agregar os scores, cada notícia é ponderada pelo inverso de sua menor distância semântica (d_i), atribuindo maior relevância aos textos mais próximos contextualmente do ativo (Equação 3).

$$w_i = \frac{1}{d_i} \quad (3)$$

Em seguida, para cada instante t , agregam-se os scores ponderados das notícias publicadas nesse horário:

$$S_t = \frac{\sum_{i: \text{data}(i)=t} w_i s_i}{\sum_{i: \text{data}(i)=t} w_i} \quad (4)$$

Finalmente, constrói-se um índice temporal contínuo e causal, $I(t_k)$, com frequência de um minuto. Define-se uma grade temporal t_k com frequência de 1 minuto entre abertura e fechamento do mercado. Com uma janela de lookback $\Delta = 1$ dia, define-se:

$$\tau_{k,i} = (t_k - t_i)_+, \quad \text{com } \tau_{k,i} \leq \Delta, \quad (5)$$

sendo t_i os instantes das notícias. A ponderação exponencial $\omega_{k,i}$ é:

$$\omega_{k,i} = \exp\left(-\frac{\tau_{k,i}}{\Delta}\right) \quad (6)$$

Para facilitar a comparação temporal e evitar o vazamento de dados futuros, os valores de S_t (calculados usando dados até t_k) são normalizados pelo valor absoluto máximo dentro da janela Δ definida, resultando em $\tilde{S}_t$:

$$\tilde{S}_t = \frac{S_t}{\max_t |S_t|_\Delta}. \quad (7)$$

Se houver pelo menos uma notícia no intervalo $(t_k - \Delta < t_i \leq t_k)$:

$$I(t_k) = \frac{\sum_{i: t_k - \Delta < t_i \leq t_k} \omega_{k,i} \tilde{S}_{t_i}}{\sum_{i: t_k - \Delta < t_i \leq t_k} \omega_{k,i}} \quad (8)$$

Caso contrário (se não houver notícias na janela), aplica-se um fator de decaimento de 0.9 ao valor anterior do índice:

$$I(t_k) = 0.9 \times I(t_{k-1}) \quad (9)$$

O índice contínuo é então interpolado e alinhado à grade temporal de preços, integrando-se como variável adicional na tabela final usada pelo modelo de aprendizado por reforço.

2.3 Ambiente de Aprendizado por Reforço

O ambiente de negociação foi implementado seguindo a interface padrão da biblioteca *Gymnasium* [7], o que garante sua compatibilidade com algoritmos modernos de RL. O ambiente simula as interações de um agente com dados de mercado, permitindo a tomada de decisões de compra, venda ou manutenção de posição.

O espaço de estados é composto por uma matriz contendo os dados dos últimos 60 períodos (uma hora) para os seguintes indicadores técnicos:

1. **Stochastic RSI**: mede a posição relativa do RSI dentro do seu intervalo recente. Parâmetros: período de 14 para o cálculo do RSI e período de 14 para o oscilador estocástico.
2. **RSI**: quantifica a velocidade e a magnitude das variações de preço. Parâmetro: período de 14.
3. **ATR**: calcula a volatilidade média com base na amplitude das variações de preço. Parâmetro: período de 14.
4. **Momentum**: avalia a taxa de variação do preço em relação a períodos anteriores. Parâmetro: período de 14.
5. **CCI**: representa o desvio do preço em relação à sua média móvel, indicando condições de sobrecompra ou sobrevenda. Parâmetro: período de 14.
6. **Stochastic**: compara o preço de fechamento atual com a faixa de preços observada em um período recente. Parâmetro: período de 14.

7. **MACD**: analisa a convergência e divergência entre duas médias móveis exponenciais. Parâmetros: períodos de 12 e 26 para as médias móveis e 9 para a linha de sinal.
8. **Volume**: avalia a variação e a intensidade do volume negociado. Parâmetro: período de 14.
9. **Bandas de Bollinger**: calcula faixas de desvio padrão em torno de uma média móvel, utilizadas para medir a volatilidade. Parâmetro: período de 20.

Estes indicadores são concatenados com um vetor que informa a posição atual do agente (comprada, vendida ou neutra) e o retorno acumulado daquela posição. Essa estrutura fornece ao agente um contexto tanto da dinâmica recente do mercado quanto de seu próprio desempenho.

O espaço de ações é discreto, com três opções: +1 (abrir posição comprada ou fechar posição vendida), 0 (manter a posição atual) e -1 (abrir posição vendida ou fechar posição comprada). A função de recompensa fornecida ao agente a cada passo é baseada no logaritmo do retorno da posição em aberto, uma abordagem que visa estabilizar o treinamento.

É fundamental destacar que o ambiente opera com simplificações importantes, adotadas para fins de compatibilidade com a literatura e para isolar a eficácia da política de decisão. Conforme Gasperov [10] e Kostanjcar e Richards [11], adotam-se duas aproximações usuais: (i) ausência de custos de transação (taxas ou *slippage*) e (ii) execução imediata da ordem no próximo instante temporal. Essas hipóteses visam eliminar variáveis externas que podem mascarar o desempenho real do algoritmo, facilitando a convergência e a redução da complexidade computacional, uma prática também adotada em fases preliminares por Li et al. [12] e Pardo et al. [13].

Crucialmente, para também evitar o viés temporal na utilização da metodologia proposta, uma ação tomada pelo agente só tem efeito no *timestamp* posterior. Essa execução no instante seguinte, além de metodologicamente necessária, é comum em discretizações de alta frequência, permitindo uma comparação padronizada que prioriza a robustez estrutural e a replicabilidade experimental.

2.4 Configuração Experimental

Para o treinamento dos agentes, foi utilizado o algoritmo *Recurrent Proximal Policy Optimization* (RPPO) [6], uma extensão do PPO [5] que incorpora redes recorrentes e é robusta em ambientes parcialmente observáveis como os mercados financeiros. Os principais hiperparâmetros incluem uma taxa de aprendizado de 0.0003, γ de 0.995 e um coeficiente de entropia de 0.005.

A arquitetura da política de decisão é composta por redes neurais distintas para a função de valor e para a política de ação, ambas utilizando camadas densas com 128 neurônios. Adicionalmente, a arquitetura inclui duas camadas LSTM com 256 unidades ocultas,

permitindo que o agente mantenha uma memória interna para capturar dependências temporais de longo prazo nos dados.

A avaliação experimental foi conduzida em dois cenários distintos para permitir uma análise comparativa. O primeiro cenário, denominado modelo de base, treina o agente utilizando exclusivamente os indicadores técnicos como variáveis de estado. O segundo cenário incorpora o índice de sentimento como uma variável adicional no espaço de estados, permitindo avaliar diretamente o impacto da informação textual na política de negociação aprendida pelo agente.

3 Resultados

Esta seção apresenta os resultados empíricos obtidos a partir da simulação das estratégias de negociação. O foco é a avaliação quantitativa do impacto da inclusão do índice de sentimento na performance e no perfil de risco das decisões automatizadas. A análise é realizada de forma comparativa entre o modelo que utiliza apenas indicadores técnicos (modelo base) e o modelo que incorpora a variável textual (modelo com sentimento).

Para garantir uma avaliação robusta, os dados históricos foram segmentados em dois períodos distintos. O período de treino compreendeu os dados de 1º de abril de 2024 a 20 de julho de 2024, utilizado para o aprendizado do agente de RL. O período de teste, subsequente e não visto pelo modelo durante o treino, se estendeu até 31 de agosto de 2024, usado para a avaliação final da performance.

3.1 Análise Comparativa de Desempenho

Para avaliar o desempenho geral, foram calculadas as estatísticas descritivas agregadas para o portfólio de ativos. Os resultados individuais de performance para cada ativo e em cada ambiente de negociação podem ser encontradas no apêndice A. Já na Tabela 1, nela é disposto as métricas de tendência central e dispersão para o Retorno Acumulado, o Sharpe Ratio e o Máximo Drawdown de ambos os modelos.

Os dados da tabela indicam que o modelo com sentimento apresentou valores médios superiores tanto para o retorno quanto para o Sharpe Ratio, além de um Drawdown Máximo médio ligeiramente menor. Contudo, o desvio padrão consideravelmente mais elevado, especialmente para o retorno, sugere uma maior variabilidade nos resultados entre os ativos. A proximidade entre os valores da mediana indica que o desempenho superior na média foi fortemente influenciado por alguns casos de performance excepcional (outliers).

Essa observação é corroborada pela análise visual dos diagramas de caixa na Figura 1. Embora as medianas de ambas as estratégias sejam próximas, o modelo com sentimento exibe uma dispersão interquartil maior e a presença de outliers positivos proeminentes. Isso reforça a hipótese de que, embora não tenha havido uma melhora generalizada, a adição de sentimento permitiu

a captura de oportunidades de alto retorno em contextos específicos.




Figura 1: Comparativo da distribuição de Retorno Acumulado, Sharpe Ratio e Drawdown Máximo para os modelos com e sem sentimento.

3.2 Análise de Risco-Retorno e Geração de Alpha

A análise do perfil de risco-retorno também demonstra que o impacto da adição de sentimento não é uniforme. Enquanto alguns ativos migraram para um quadrante de maior retorno e menor risco, outros tiveram seu perfil deteriorado. Esse comportamento evidencia que o valor da informação textual é heterogêneo e depende das características de cada ativo.

Tabela 1: Estatísticas descritivas dos modelos com e sem sentimento.

Métrica	Ret. Acumulado		Sharpe Ratio		Max DD	
	Base	Sentimento	Base	Sentimento	Base	Sentimento
Média	0.02	0.20	0.07	0.14	-0.20	-0.16
Mediana	0.05	0.06	0.08	0.08	-0.15	-0.14
Desvio Padrão	0.25	0.53	0.14	0.23	0.19	0.10

Para avaliar a capacidade de gerar retornos excedentes, analisou-se o Alpha, definido como a diferença entre o retorno da estratégia e o retorno do ativo em uma abordagem *buy and hold*. A distribuição do Alpha, apresentada na Figura 2, mostra que ambas as estratégias apresentaram medianas levemente positivas, indicando uma capacidade marginal de superar o benchmark. No entanto, a estratégia com sentimento demonstrou uma cauda superior mais longa e um outlier com valor extremo, sugerindo um potencial maior para a geração de valor, ainda que associado a um risco mais elevado. Em contraste, o modelo de base apresentou uma distribuição mais concentrada, operando de forma mais conservadora, com menor potencial para ganhos ou perdas excepcionais.




Figura 2: Distribuição do Alpha (Retorno Acima do Benchmark) para as estratégias com e sem sentimento.

3.3 Impacto Direto e Significância Estatística

Para isolar a contribuição da variável de sentimento, foi analisada a distribuição da diferença (delta) de performance entre os dois modelos. Os histogramas na Figura 3 revelam uma assimetria à direita tanto para a diferença no Sharpe Ratio quanto no Retorno Acumulado. A maioria dos ativos apresentou variações modestas, próximas de zero, mas uma minoria exibiu melhorias substanciais, sendo responsável por elevar o desempenho médio geral.

Essa dualidade de resultados fica evidente ao analisar os casos de maior destaque, conforme apresentado na Tabela 2. Ativos como Coca-Cola (KO) e NVIDIA (NVDA) foram fortemente beneficiados pela inclusão do sentimento, enquanto outros, como Chevron (CVX) e Apple (AAPL), sofreram uma deterioração no desempenho ajustado ao risco.

Distribuição do Impacto do Sentimento na Performance




Figura 3: Distribuição do impacto da adição de sentimento na performance, medido pela diferença no Sharpe Ratio e no Retorno Acumulado.

Finalmente, para verificar se as diferenças observadas eram estatisticamente relevantes, foi aplicado o Teste t pareado. O teste foi conduzido com um nível de significância de $\alpha = 0,05$. A Tabela 3 resume os resultados.

Os p-valores obtidos para todas as métricas foram superiores ao nível de significância adotado, levando à não rejeição da hipótese nula. Portanto, apesar das melhorias expressivas observadas em casos individuais, não é possível afirmar, com base estatística, que a adição do índice de sentimento promoveu um efeito sistemático e generalizável no desempenho das estratégias para o universo de ativos testados. Os ganhos parecem ser pontuais e não representam uma melhoria estatisticamente significativa no agregado.

3.4 Análise Agregada dos Resultados

A análise comparativa dos modelos com e sem a variável de sentimento demonstrou a viabilidade de integrar o PLN ao sistema de decisão por RL. Observou-

Tabela 2: Casos de destaque com base na variação do Sharpe Ratio.

Categoria	Ticker	Sharpe Base	Sharpe Sentimento	Δ Sharpe
Maior Melhora	KO	0.19	0.91	+0.72
Maior Melhora	NVDA	-0.33	0.33	+0.66
Pior Piora	CVX	0.08	-0.12	-0.20
Pior Piora	AAPL	0.12	-0.07	-0.19

Tabela 3: Resultados do Teste t Pareado entre os modelos.

Métrica	p-valor	Diferença Significativa ($\alpha = 0,05$)
Sharpe Ratio	0,1629	Não
Retorno Acumulado	0,2562	Não
Max Drawdown	0,2196	Não

se um impacto positivo, embora moderado, na performance. O comportamento dos modelos reforça a hipótese de que a informação qualitativa, extraída de textos, pode adicionar robustez à estratégia, e o modelo com sentimento frequentemente apresentou melhores indicadores de risco-retorno.

Quantitativamente, o modelo com sentimento obteve desempenho superior em aproximadamente 60% dos ativos analisados, com destaque para casos como NVIDIA (NVDA). Contudo, é provável que esses resultados extremos sejam, em parte, amplificados pela ausência de fricções de mercado na simulação. Em um ambiente real, a inclusão de custos de transação, como taxas e *slippage*, penalizaria estratégias que dependem de um alto volume de operações – exatamente o tipo de comportamento que poderia levar a ganhos atípicos.

Contudo, a melhoria não foi uniforme, sendo nula ou pouco expressiva em outros ativos. Isso aponta para limitações na generalização do método, possivelmente pela abrangência limitada das fontes de notícias ou pelo ruído inerente ao modelo de classificação *FinBERT* [4]. De fato, a análise estatística (Teste t pareado) não demonstrou significância estatística ($\alpha = 0,05$) nas diferenças de desempenho.

Portanto, embora os ganhos não sejam generalizáveis estatisticamente para todo o portfólio, os resultados são satisfatórios dentro das limitações do estudo e validam o uso do PLN como uma fonte de informação auxiliar relevante para sistemas de decisão autônomos.

4 Conclusão

Este trabalho investigou a integração entre Processamento de Linguagem Natural (PLN) e algoritmos de Aprendizado por Reforço (RL) para a construção de sistemas de decisão automatizados. A proposta central foi transformar dados textuais não estruturados, extraídos de notícias financeiras, em sinais quantitativos (um índice de sentimento) e analisar o impacto dessa informação em estratégias de negociação algorítmica.

A execução do projeto demonstrou a viabilidade técnica da abordagem. A metodologia permitiu a construção de uma arquitetura modular e reproduzível. A análise empírica, por sua vez, revelou que a inclusão do índice de sentimento, embora não tenha promovido

uma melhora estatisticamente significativa de forma agregada, influenciou positivamente o desempenho e o perfil de risco-retorno de ativos específicos, indicando a relevância de integrar sinais qualitativos em decisões automatizadas.

4.1 Análise Crítica da Solução Desenvolvida

Embora a solução tenha demonstrado viabilidade, uma análise crítica exige o reconhecimento das simplificações adotadas, que influenciam a aplicabilidade do modelo em cenários reais.

A principal simplificação foi a desconsideração dos custos de transação e da latência de execução. Em um ambiente real, essas fricções impactam negativamente a rentabilidade e podem inviabilizar estratégias com alto volume de operações. A ausência desses custos, deliberadamente adotada para isolar o impacto da variável de sentimento, pode superestimar os retornos e favorecer a ocorrência de *outliers* de desempenho, como o observado no ativo NVIDIA (NVDA).

Esta abordagem, embora criticável do ponto de vista prático, é uma escolha metodológica deliberada e recorrente na literatura para facilitar a convergência da política de aprendizado por reforço utilizada. Trabalhos como os de Li et al. [12] e Pardo et al. [13] também assumem execução perfeita e zero fricção em fases preliminares. Da mesma forma, estudos como Richards [11] e Gasperov e Kostanjcar [10] seguem essa linha ao construir ambientes que priorizam a robustez estrutural e a replicabilidade experimental. A comparação com esses trabalhos, portanto, reside na paridade metodológica.

Além disso, outras limitações importantes incluem:

- **Fonte de Dados:** O sistema depende de uma única fonte de dados (API da *Alpha Vantage* [8]) tanto para preços quanto para notícias, criando um ponto único de falha e limitando a diversidade da informação.
- **Granularidade Temporal:** A construção do índice de sentimento utiliza uma janela de um dia, uma abordagem que, embora estável, pode não capturar reações de altíssima frequência a eventos noticiosos, perdendo oportunidades intradiárias. Trabalhos futuros poderiam investigar o impacto de

diferentes janelas de *lookback* (horas ou minutos) para otimizar a responsividade do índice.

- Modelo de PLN: O *FinBERT* [4], apesar de especializado, possui limitações intrínsecas para interpretar sarcasmo ou ambiguidades, podendo introduzir ruído no sinal de sentimento.
- Métrica de Ponderação: A própria metodologia de classificação contextual, baseada no inverso da distância euclidiana, poderia ser revista. Trabalhos futuros poderiam explorar o uso da proximidade por cossenos para avaliar a relevância semântica, uma métrica que pode ser mais robusta em espaços de alta dimensão como os gerados pelos *embeddings*.
- Análise Estatística: A análise de significância foi limitada ao Teste t pareado. Para complementar a análise, testes não paramétricos, como o teste pareado de Wilcoxon, poderiam ser úteis, especialmente caso as distribuições das métricas não atendam aos pressupostos do teste t.

4.2 Conclusões Finais e Trabalhos Futuros

Este trabalho alcançou seu objetivo principal ao demonstrar que o PLN pode ser efetivamente incorporado a modelos de decisão baseados em RL. Ainda que os resultados não tenham sido uniformemente superiores, o experimento validou a utilidade da informação textual como fonte auxiliar para complementar dados quantitativos tradicionais.

As limitações identificadas na análise crítica definem claramente os próximos passos para a evolução do projeto. Sugere-se como trabalhos futuros a construção de um ambiente de simulação mais realista, incorporando custos de transação, *slippage* e modelos de latência de execução. Adicionalmente, a agregação de múltiplas fontes de notícias para mitigar vieses, a exploração de técnicas de PLN mais avançadas para a geração do índice de sentimento em frequências mais altas (intradiaárias), e o refinamento da função de recompensa do agente de RL para penalizar explicitamente o risco, a volatilidade ou a frequência excessiva de operações são caminhos promissores. Por fim, a experimentação com arquiteturas de redes neurais mais sofisticadas, como mecanismos de atenção temporal, e outros algoritmos de RL, como A3C [14] ou DDPG [15], também é recomendada.

Em suma, a convergência entre PLN e RL representa um campo fértil para a engenharia mecatrônica, e o estudo aqui realizado serve como um exemplo sistemático de como essa integração pode ser conduzida para o desenvolvimento de sistemas autônomos mais inteligentes e adaptativos.

Referências

- [1] C.-J. Wang, M.-F. Tsai, T. Liu e C.-T. Chang, “Financial Sentiment Analysis for Risk Prediction,” em *Proceedings of the 6th International Joint Conference on Natural Language Processing*, Asian Federation of Natural Language Processing, 2013, pp. 1162–1170. endereço: <https://aclanthology.org/I13-1097>.
- [2] A. Vaswani et al., “Attention is All you Need,” em *Advances in Neural Information Processing Systems*, I. Guyon et al., ed., vol. 30, Curran Associates, Inc., 2017. endereço: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.
- [3] J. Devlin, M.-W. Chang, K. Lee e K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” em *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, ACL, 2019, pp. 4171–4186. endereço: <https://aclanthology.org/N19-1423/>.
- [4] A. H. Huang, H. Wang e Y. Yang, “FinBERT: A Large Language Model for Extracting Information from Financial Text,” *Contemporary Accounting Research*, 2023. DOI: 10.1111/1911-3846.12832. endereço: <https://onlinelibrary.wiley.com/doi/abs/10.1111/1911-3846.12832>.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford e O. Klimov, “Proximal Policy Optimization Algorithms,” *arXiv preprint arXiv:1707.06347*, 2017. endereço: <https://arxiv.org/abs/1707.06347>.
- [6] M. Pleines, M. Pallasch, F. Zimmer e M. Preuss, “Generalization, Mayhems and Limits in Recurrent Proximal Policy Optimization,” *arXiv preprint arXiv:2205.11104*, 2022. endereço: <https://arxiv.org/abs/2205.11104>.
- [7] F. Foundation, *Gymnasium: A standard API for reinforcement learning environments*, <https://gymnasium.farama.org>, Acesso em: 2025-04-15, 2025.
- [8] Alpha Vantage Inc., *Alpha Vantage - Stock APIs and Financial Market Data*, <https://www.alphavantage.co/>, Acesso em: 2025-04-16, 2025.
- [9] L. Richardson, *beautifulsoup4*, <https://pypi.org/project/beautifulsoup4/>, Accessed: 2025-05-14, 2025.
- [10] B. Gasperov e Z. Kostanjcar, “Market making with signals through deep reinforcement learning,” *IEEE Access*, v. 9, pp. 92 416–92 433, 2021.

- [11] N. Richards, “Reinforcement learning for algorithmic day trading on the Johannesburg Stock Exchange,” tese de dout., Stellenbosch University, 2023. endereço: <https://scholar.sun.ac.za/handle/10019.1/126965>.
- [12] Y. Li, W. Zheng e Z. Zheng, “Deep robust reinforcement learning for practical algorithmic trading,” *IEEE Access*, v. 7, pp. 83 571–83 584, 2019.
- [13] F. M. Pardo, C. Auth e F. Dascalu, “A modular framework for reinforcement learning optimal execution,” *arXiv preprint arXiv:2208.06244*, 2022.
- [14] V. Mnih et al., “Asynchronous methods for deep reinforcement learning,” *International conference on machine learning*, pp. 1928–1937, 2016. endereço: <https://arxiv.org/abs/1602.01783>.
- [15] T. P. Lillicrap et al., “Continuous control with deep reinforcement learning,” *arXiv preprint arXiv:1509.02971*, 2015. endereço: <https://arxiv.org/abs/1509.02971>.

A Métricas de Desempenho obtidas Sem e Com o Índice de Sentimento

Tabela 4: Desempenho da Estratégia **sem** o Índice de Sentimento.

Ticker	Ret. Estratégia	Ret. Original	Sharpe	Max DD	Best Day	Worst Day
AAPL	12.48%	2.33%	0.12	-14.33%	14.58%	-12.73%
AMZN	4.79%	-2.34%	0.07	-13.14%	8.66%	-7.92%
BA	4.93%	-3.38%	0.08	-14.99%	10.26%	-9.45%
BAC	33.46%	-2.65%	0.33	-6.89%	7.61%	-5.92%
CAT	17.16%	2.20%	0.25	-10.36%	4.64%	-4.24%
CVX	4.45%	-6.04%	0.08	-12.89%	12.53%	-11.12%
DE	11.97%	1.88%	0.18	-14.67%	4.96%	-4.56%
DIS	10.03%	-5.24%	0.12	-23.48%	6.98%	-21.42%
F	8.15%	-5.32%	0.10	-17.43%	11.52%	-10.33%
GE	-6.42%	9.44%	-0.01	-16.41%	6.93%	-7.36%
GOOG	26.73%	-8.03%	0.21	-13.68%	7.51%	-7.09%
GS	-11.05%	6.00%	-0.10	-18.66%	7.84%	-8.66%
INTC	14.53%	-32.69%	0.11	-31.83%	45.78%	-31.37%
KO	10.17%	10.89%	0.19	-3.40%	2.62%	-2.55%
MCD	-9.99%	12.27%	-0.08	-17.55%	7.41%	-7.45%
META	18.31%	9.31%	0.18	-28.33%	7.30%	-9.10%
MSFT	-13.80%	-4.30%	-0.10	-22.85%	6.42%	-7.42%
NVDA	-99.59%	-49.91%	-0.33	-99.62%	50.42%	-77.31%
ORCL	-4.11%	2.05%	-0.04	-15.13%	5.19%	-4.75%
PFE	-3.43%	-1.88%	0.00	-11.82%	10.86%	-9.80%
TSLA	-3.37%	-11.84%	0.00	-22.41%	9.63%	-13.77%
V	14.25%	4.23%	0.17	-9.67%	6.90%	-6.49%
XOM	-3.50%	2.44%	-0.02	-9.92%	6.14%	-5.71%

Tabela 5: Desempenho da Estratégia **com** o Índice de Sentimento.

Ticker	Ret. Estratégia	Ret. Original	Sharpe	Max DD	Best Day	Worst Day
AAPL	-3.31%	2.33%	-0.07	-8.33%	4.82%	-5.02%
AMZN	-10.84%	-2.34%	-0.03	-21.64%	7.92%	-8.66%
BA	33.16%	-3.38%	0.25	-14.29%	9.45%	-10.26%
BAC	21.53%	-2.65%	0.22	-12.28%	7.61%	-8.64%
CAT	24.46%	2.20%	0.35	-9.37%	4.24%	-4.64%
CVX	-8.73%	-6.04%	-0.12	-11.65%	6.78%	-6.96%
DE	7.52%	1.88%	0.15	-12.17%	4.56%	-4.48%
DIS	-5.78%	-5.24%	0.05	-23.77%	24.61%	-19.75%
F	54.46%	-5.32%	0.38	-25.27%	11.52%	-10.33%
GE	-15.84%	9.44%	-0.09	-19.91%	6.83%	-7.36%
GOOG	2.63%	-8.03%	0.05	-9.76%	7.09%	-7.27%
GS	18.28%	6.00%	0.22	-14.39%	8.66%	-7.84%
INTC	18.36%	-32.69%	0.22	-11.96%	10.61%	-11.91%
KO	54.37%	10.89%	0.91	-2.56%	2.62%	-2.55%
MCD	-7.66%	12.27%	-0.06	-16.41%	7.20%	-7.45%
META	6.45%	9.31%	0.08	-16.29%	8.37%	-9.10%
MSFT	-2.78%	-4.30%	-0.00	-16.13%	7.45%	-6.97%
NVDA	247.10%	-49.91%	0.33	-50.42%	101.71%	-50.42%
ORCL	-3.36%	2.05%	0.01	-25.59%	13.70%	-16.58%
PFE	4.30%	-1.88%	0.07	-13.00%	9.80%	-10.86%
TSLA	-14.85%	-11.84%	-0.15	-25.92%	7.13%	-6.66%
V	10.18%	4.23%	0.13	-9.48%	6.90%	-6.49%
XOM	21.80%	2.44%	0.34	-6.14%	5.71%	-6.14%